Kaos Sınırında Gradyan: HydroGym'de Analitik Gradyan Yöntemlerinin Kırılma Noktası

(Subtitle: HydroGym Kolmogorov Akışında PPO, GPPO, SAC ve GSAC'ın Kırılma-Noktası Karşılaştırması)

Haktan Güloğlu
Sakarya Üniversitesi, Milli Teknoloji Atölyesi, Yapay Zeka Merkezi
haktanguloglu24@gmail.com

Durum: Genişletilmiş taslak, tam kaynakçalı (n=25 literatür taraması entegre edilmiştir). İkinci bir eğitim seed'i (seed=1) ile tam 8-konfigürasyonluk doğrulama koşusu **tamamlanmıştır**; bulgular n=2 (seed=0, seed=1) üzerinden raporlanmaktadır. Bu doğrulama, n=1'de gözlenen "temiz çarpımsal" gecikme deseninin ikinci seed'te **tekrarlanmadığını** — özellikle off-policy yapının tek başına kararlılığı artırdığı iddiasının yön değiştirdiğini — ortaya çıkarmıştır; buna karşın **GSAC'ın her iki seed'de de dört yöntem içinde en dayanıklısı olması tutarlı kalmıştır**.

Özet

Bu çalışma, analitik (diferansiyellenebilir-simülasyon üzerinden hesaplanan) politika gradyanı kullanan pekiştirmeli öğrenme yöntemlerinin **kaos sınırındaki kırılma noktasını** — eğitimin sayısal olarak ıraksadığı ilk episode'u — kaotik bir akışkanlar dinamiği kontrol görevinde nicel olarak karakterize eder. *Nature*'da yayımlanan HydroGym platform makalesi [1], 61'den fazla doğrulanmış akış kontrolü ortamı sunan, çözücüden bağımsız bir pekiştirmeli öğrenme (RL) platformu tanımlar ve JAX tabanlı diferansiyellenebilir Kolmogorov akışı ortamında **Gradyan-Zenginleştirilmiş PPO (GPPO)**'nun eğitim iterasyonlarını standart PPO'ya kıyasla **en az %65 azalttığını** raporlar. Ancak bu sonuç, makalenin tanımladığı geniş Reynolds aralığının (Re=40–500) **yalnızca tek bir noktasında, tek eğitim seed'iyle** gösterilmiştir; analitik gradyan enjeksiyonunun düzenli (laminer) ve kaotik (türbülanslı) rejimlerde nasıl farklı davrandığı ayrıca test edilmemiştir. Bu boşluk, kaotik dinamiklerde geri-yayılan gradyanların sistem Jacobian'ının spektrumu nedeniyle kararsızlaştığını gösteren genel bir bulguyla [7] ve türbülansın Lyapunov üstelinin Reynolds sayısıyla büyüdüğünü gösteren klasik bir sonuçla [25] örtüşmektedir.

Bu çalışma, gerçek `hydrogym.jax.envs.kolmogorov.KolmogorovFlow` ortamı üzerinde dört algoritmayı — PPO, GPPO, literatürde HydroGym'e daha önce uygulanmamış SAC [8] ve onun analitik-gradyanla zenginleştirilmiş hâli **GSAC** — düzenli (Re=45) ve kaotik (Re=300) rejimlerde, 500 episode'luk bütçelerle, **iki bağımsız eğitim seed'i (seed=0, seed=1)** üzerinden test eder. Re=45'te GPPO'nun örnekleme avantajı her iki seed'de de doğrulanır (seed=0'da %63, seed=1'de %77 episode tasarrufu; makalenin bildirdiği %65'e [1] her iki değer de yakın büyüklük mertebesindedir). Re=300'de ise dört algoritma da sayısal kararsızlığa (NaN) düşer, ancak kırılma zamanı hem algoritmaya hem de **seed'e** göre çarpıcı biçimde farklılaşır: seed=0'da PPO 12., SAC 36., GPPO 83., GSAC 141. episode'da çöker (PPO'ya göre 3.0×, 6.9×, 11.8× gecikme); seed=1'de ise PPO 35., **SAC 6.** (PPO'dan **daha erken**, 0.17×), GPPO 40., GSAC 63. episode'de çöker. İkinci seed, n=1'de gözlenen "off-policy yapı tek başına kararlılığı artırır" iddiasını **doğrulamamış**, hatta tersine çevirmiştir; buna karşın analitik gradyan enjeksiyonunun gecikme yönü (GPPO>PPO, GSAC>SAC) ve **GSAC'ın dört yöntem içinde her iki seed'de de en dayanıklısı olması** tutarlı kalmıştır. Ham eğitim eğrilerinin incelenmesi, kırılmanın öncülsüz/ani bir olay olduğunu ve kalıcı-çöküş öncesi kısa bir "hayatta kalma" penceresinin (yalnızca seed=0'ın GSAC'ında gözlenen) bir replay-tamponu seyreltme mekanizmasıyla nicel olarak açıklanabildiğini — ve bu mekanizmanın seed=1'in farklı sonucunu da doğru öngördüğünü — göstermektedir (§5.3). Bulgular, analitik gradyan enjeksiyonunun kaotik rejimde kararsızlığı ortadan kaldırmadığını, yalnızca **ertelediğini** ve bu erteleme büyüklüğünün seed'e bağlı olarak büyük varyans gösterdiğini; off-policy yapının bu erteleyici etkiyi yalnızca analitik gradyanla **birlikte** güvenilir biçimde sağladığını ortaya koymaktadır.

Anahtar Kelimeler: pekiştirmeli öğrenme, diferansiyellenebilir simülasyon, analitik politika gradyanı, akışkanlar dinamiği kontrolü, kaotik dinamikler, PPO, SAC

Abstract

*(Title: "Gradient at the Edge of Chaos: The Breaking Point of Analytic Gradient Methods in HydroGym") This work characterizes the **breaking point at the edge of chaos** — the first episode at which training numerically diverges — for analytic-gradient reinforcement learning methods on a chaotic fluid-dynamics*

control task. The Nature paper introducing HydroGym [1] reports that Gradient-Enhanced PPO (GPPO) reduces training iterations on the differentiable Kolmogorov-flow environment by at least 65% relative to standard PPO, demonstrated at a single point within the paper's tested Reynolds range (Re=40–500) with a single training seed. We evaluate PPO, GPPO, SAC [8], and a novel gradient-enhanced SAC variant (GSAC) on the real `hydrogym.jax` *Kolmogorov-flow environment at a regular (Re=45) and a chaotic (Re=300) operating point, across* ***two independent training seeds (seed=0, seed=1)****. At Re=45, GPPO's sample-efficiency advantage is reproduced in both seeds (63% and 77% fewer episodes to reach PPO's best reward). At Re=300, all four algorithms eventually diverge numerically, but the episode at which divergence first occurs differs sharply by both algorithm and seed: in seed=0, PPO breaks at episode 12, SAC at 36, GPPO at 83, GSAC at 141 (3.0×, 6.9×, 11.8× delay vs. PPO); in seed=1, PPO breaks at 35,* ***SAC at 6*** *(earlier than PPO, 0.17×), GPPO at 40, GSAC at 63. The second seed does* ***not*** *reproduce the n=1 claim that off-policy training alone delays instability — that direction reverses — but the delaying effect of analytic-gradient injection and, most importantly,* ***GSAC being the most robust of the four algorithms****, replicate in both seeds. A replay-buffer dilution mechanism quantitatively explains a short post-trigger survival window observed only for GSAC in seed=0, and correctly predicts its absence in seed=1 (§5.3). We conclude that analytic gradient injection delays — but does not eliminate — instability under chaotic dynamics, that the size of this delay varies substantially across seeds, and that off-policy training only reliably contributes to this delay when combined with analytic gradient injection.*

1. Giriş

Akışkanlar dinamiğinin aktif kontrolü — sürükleme azaltımı, karışım artırımı, aşırı olay bastırma gibi hedeflerle — pekiştirmeli öğrenmenin son yıllarda en aktif uygulama alanlarından biri hâline gelmiştir. Alanın kurucu çalışması olan Rabault ve ark. [23], derin RL'nin bir silindir arkasındaki periyodik girdap dökülmesini kontrol ederek Re=100'de %8 sürükleme azaltımı sağlayabildiğini ilk kez göstermiş; bu çizgi, türbülanslı ayrılma kabarcığı kontrolü [10] ve gerçek zamanlı, durum-bağımlı türbülanslı iz (wake) kontrolü [24] gibi çalışmalarla türbülans rejimine genişlemiştir. HydroGym [1], bu dağınık kod tabanlarını tek, çözücüden bağımsız bir platformda birleştirerek laminerden türbülansa 61'den fazla ortam sunar ve LBM, FEM gibi klasik çözücülerin yanı sıra JAX [13] tabanlı, uçtan uca **diferansiyellenebilir** bir çözücü de içerir — bu çözücü altyapısı, JAX-CFD [14] ve JAX-Fluids [15,16] gibi öncü diferansiyellenebilir CFD kütüphanelerinin doğrudan bir devamıdır. Benzer motivasyonla geliştirilen, PyTorch tabanlı ve tamamen diferansiyellenebilir bir başka akış-kontrolü kıyaslama paketi olan FluidGym [2] da bu ekosistemin metodolojik bir akrabasıdır.

Diferansiyellenebilirlik, standart model-serbest RL'nin ötesine geçip **analitik politika gradyanlarını** — ödülün politika parametrelerine göre türevini, örnekleme yerine doğrudan zincir kuralıyla, simülatörün kendisi üzerinden hesaplama imkânı sunar. HydroGym makalesi bu imkânı GPPO ile gösterir ve Kolmogorov akışı ortamında eğitim iterasyonlarını en az %65 azalttığını raporlar [1]. Ne var ki bu sonuç **tek bir çalışma noktasında** gösterilmiş olup, makalenin tanımladığı geniş Re=40–500 aralığının düzenli ve kaotik uçlarında analitik gradyanın davranışı ayrıca karşılaştırılmamıştır.

Bu boşluk, diferansiyellenebilir programlama literatüründe iyi bilinen bir riskle örtüşür. Metz ve ark. [7], yinelenen haritalarda, sayısal fizik simülasyonlarında ve öğrenilmiş optimize edicilerde ortak bir "kaos-kaynaklı başarısızlık modu" göstermiş; bunu sistemin Jacobian'ının spektrumuna bağlamıştır. Akışkanlar-dinamiği tarafında ise Boffetta ve Musacchio [25], homojen-izotropik türbülansta en büyük Lyapunov üstelinin Reynolds sayısıyla birlikte büyüdüğünü ve öngörü ufkunun bu üstelle ters orantılı olarak daraldığını göstermiştir. Bu iki bağımsız teorik dayanak, kaotik bir rejimde analitik gradyanın normunun/yönünün kelebek etkisiyle aşırı duyarlı hâle gelmesini ve GPPO'nun bildirilen avantajının Re arttıkça zayıflayabileceğini, hatta tersine dönebileceğini düşündürür.

Analitik gradyan enjeksiyonu şimdiye dek ağırlıklı olarak **on-policy** yöntemlerle veya rijit-gövde/temaslı robotik görevlerinde uygulanmıştır: SHAC [3], kısa-ufuklu rollout'lar ve öğrenilmiş bir terminal değer fonksiyonuyla patlayan/kaybolan gradyan sorununu hafifletir; AHAC [5] bu fikri, ufku sert dinamiklerden kaçınacak şekilde **adaptif olarak** ayarlayarak bir adım öteye taşır. Off-policy tarafta ise SAPO [4], analitik-gradyan RL'yi maksimum-entropi bir çerçeveye taşıyarak deforme-olabilir cisim görevlerinde üstün performans göstermiştir — ancak bu yaklaşım hiç akışkanlar dinamiğine uygulanmamıştır. Bu çalışma, SAC [8]'ın analitik gradyanla zenginleştirilmiş bir versiyonu olan **GSAC**'ı dördüncü yöntem olarak ekleyerek, GPPO (SHAC ailesi) ile SAPO ailesinin kesişimini akışkanlar dinamiğine taşır.

Katkılar

• HydroGym'in Kolmogorov akışı üzerindeki GPPO-vs-PPO sonucunu [1], tek bir Re noktasından düzenli–kaotik bir rejim karşılaştırmasına genişletiyoruz.

• Literatürde HydroGym'e hiç uygulanmamış bir GSAC (SAC + analitik gradyan, SAPO [4] ailesinin akışkanlar dinamiğine ilk taşınması) varyantı sunuyor ve kararlılık avantajının kaynağının "analitik gradyan" mı yoksa "off-policy eğitim yapısı" mı olduğunu ilk kez ayrıştırıyoruz.

• Kaotik rejimde dört algoritmanın da sayısal olarak ıraksadığını, ama ıraksama zamanının hem algoritmaya hem de eğitim seed'ine göre büyük ölçüde değiştiğini (12–141 episode aralığında) gösteriyoruz. **İki bağımsız seed'in** karşılaştırılması, n=1'de gözlenen "temiz çarpımsal katkı" deseninin bir yapıt olduğunu ortaya koyuyor: analitik gradyanın geciktirici etkisi yön olarak her iki seed'de de tutarlı kalırken (GPPO>PPO, GSAC>SAC), off-policy yapının **tek başına** geciktirici olduğu iddiası seed=1'de tersine dönüyor. Tek istikrarlı bulgu, **GSAC'ın her iki seed'de de en dayanıklısı olması**dır.

• Ham eğitim eğrilerini doğrudan inceleyerek kırılmanın mekanizmasını karakterize ediyoruz: kırılma öncesinde görünür bir öncül yoktur (ani, stokastik bir tetiklenme, her iki seed'de de gözlenir); off-policy yöntemlerde replay tamponunun zehirli geçişleri seyreltmesi birkaç episode'luk bir kalıcı-çöküş ertelemesi yaratabilir — bu mekanizmadan türetilen nicel tahmin, seed=0'daki 2-episode'luk ertelemeyi **ve** seed=1'de erteleme gözlenmemesini **her ikisini de** doğru öngörür (§5.3).

Hipotez: Analitik gradyanın normu/varyansı düşük Re'de kararlı, yüksek Re'de kararsız olacak; bu kararsızlığa karşı GSAC'ın off-policy yapısı, GPPO'nun on-policy yapısından daha dayanıklı kalacaktır. **(n=2 sonucu:** GSAC'ın GPPO'dan daha dayanıklı olması her iki seed'de de doğrulanmıştır (seed=0: 141

vs 83; seed=1: 63 vs 40); ancak bunun nedeni "off-policy yapı tek başına daha dayanıklı" değil, off-policy yapının yalnızca analitik gradyanla **birlikte** güvenilir bir katkı sağlamasıdır — bkz. §5.2.)

2. İlgili Çalışmalar

2.1 RL ile Akış Kontrolü ve HydroGym

HydroGym [1], farklı çözücüleri tek bir RL arayüzü altında birleştirerek laminerden türbülansa 61+ ortam sunar; öğrenilen kontrol politikalarının ortamlar arasında sıfır-atış transfer edilebildiğini (ör. 3B kanat kesitinde %38 sürükleme azaltımı) ve GPPO ile Kolmogorov akışında ≥%65 örnekleme kazancı sağlandığını gösterir. FluidGym [2], metodolojik olarak akraba, PyTorch-tabanlı ve tamamen diferansiyellenebilir bir başka akış-kontrolü kıyaslama paketidir. Bu çalışma, HydroGym'in bildirdiği kazanımın Reynolds sayısına duyarlılığını inceler.

2.2 Diferansiyellenebilir Simülasyon Üzerinden Analitik Politika Gradyanları

GPPO'nun ait olduğu daha geniş yöntem ailesi, önce robotik/kontrol literatüründe ortaya çıkmıştır. SHAC [3], kısa-ufuklu rollout'lar ve pürüzsüz bir kritik fonksiyonuyla analitik gradyanı tam episode ufkundan ayırarak patlayan/kaybolan gradyan sorununu hafifletir; muscle-actuated lokomosyon görevlerinde 17 kattan fazla eğitim-süresi azalması bildirir — GPPO/GSAC'ta kullanılan 6-adımlık kısa ufuk tasarımı bu yaklaşımın doğrudan bir uyarlamasıdır. AHAC [5], ufku sert dinamiklerden kaçınacak şekilde adaptif ayarlayarak lokomosyon görevlerinde model-serbest temel çizgilere göre %40 daha fazla ödül elde eder. SAPO [4], bu fikri maksimum-entropi off-policy bir çerçeveye taşır. Bu çalışmadaki GSAC, SAPO'nun temel fikrini akışkanlar dinamiğine taşıyan ilk uygulamadır.

2.3 Kaotik Sistemlerde Analitik Gradyan Kararsızlığı

Hipotezimizin teorik dayanağı Metz ve ark. [7]: kaotik dinamik sistemlerde geri yayılan gradyanların, sistem Jacobian'ının spektrumundan kaynaklanan bir kelebek-etkisi mekanizmasıyla patladığını gösterir. Bu genel gözlemin akışkanlar-dinamiği karşılığı Boffetta ve Musacchio [25]: homojen-izotropik türbülansta en büyük Lyapunov üstelinin Reynolds sayısıyla büyüdüğünü ve öngörü ufkunun bu üstelle ters orantılı olarak daraldığını gösterir. Bu iki kaynak birlikte, sonuçlarımızdaki "GPPO ve GSAC de sonunda NaN'a düşüyor, ama çok daha geç" bulgusunun teorik zeminini oluşturur.

2.4 Analitik Gradyan mı, Zeroth-Order mi? Kısmi Diferansiyellenebilirlik

Suh ve ark. [20], analitik ve zeroth-order politika gradyanlarını sertlik ve süreksizlik içeren sistemlerde karşılaştırır ve bir α-dereceli karma kestirici önerir — GSAC'taki %50-%50 karışım tasarımının kabaca özel bir hâlidir. Bu çalışmanın 2026 tarihli bir takip analizi [21], daha hafif bir hibrit-geçiş testi (DDCG) önererek aynı soruyu güncel deneylerle yeniden sınar. ABPT [22], ödülün yalnızca kısmen diferansiyellenebilir olduğu durumlar için düzeltilmiş bir BPTT şeması önerir.

2.5 Temel Pekiştirmeli Öğrenme Algoritmaları

Karşılaştırmanın iki gradyansız çıpası: Schulman ve ark. [6]'nın PPO'su ve Haarnoja ve ark. [8,9]'ın Soft Actor-Critic'i. PPO'nun avantaj kestirimi, TRPO [17] ve Genelleştirilmiş Avantaj Kestirimi (GAE) [18]'e dayanır; SAC'ın maksimum-entropi çerçevesinin kökeni olan Soft Q-learning [19], entropi düzenlileştirmesinin off-policy öğrenmede neden GSAC'ın kaotik rejimde daha dayanıklı kaldığını açıklayan teorik zemini sağlar.

2.6 Akışkanlar Dinamiğinde RL Tabanlı Aktif Akış Kontrolü (Bağlam)

Rabault ve ark. [23]'ın kurucu çalışmasından beri, gradyansız RL'nin türbülanslı akış kontrolünde başarılı olduğu tekrar tekrar gösterilmiştir: türbülanslı ayrılma kabarcığı kontrolü [10] klasik periyodik zorlamaya göre %9'a karşı %6.8 azaltım sağlar; erken bir çalışma [11] DRL'nin türbülanslı koşullara uygulanabilirliğini gösterir; gerçek zamanlı bluff-body iz kontrolü [24] rüzgar tüneli deneylerinde model-tabanlı temel çizgilere göre 2–4× performans elde eder. Bu kaynaklar hiçbiri analitik gradyan enjeksiyonunu kaotik/türbülanslı rejimle sistematik olarak karşılaştırmaz — bu çalışmanın hedeflediği boşluk tam olarak burasıdır.

3. Yöntem

3.1 Ortam

Deneyler, gerçek `hydrogym.jax.envs.kolmogorov.KolmogorovFlow` ortamında yürütülmüştür: 64×64 ızgara (4096 serbestlik derecesi), pseudo-spektral IMEX-RK4CN zaman entegrasyonu [1,13–16], 4 aktüatör modu. Bu çalışma, kütüphanenin resmi GPPO uygulamasını değil, aynı mekanizmayı (§3.3) kendi PPO/SAC eğitim döngümüz içinde yeniden uygulayan bağımsız bir kod tabanı kullanır; makalenin GPPO için kullandığı tam karışım oranı, ufuk uzunluğu ve hiperparametreler yayımlanmış metinde/şekil başlıklarında verilmediğinden, §3.3–3.4'te tanımlanan seçimler **kendi yeniden-uygulamamıza** aittir.

Kütüphanenin `step_env` fonksiyonu, çağrı sırasında geçirilen `params.dt`/`params.action_time` değerlerini yok sayıp bunun yerine `self.default_params`'ı tekrar okur; bu yüzden zaman adımı ve eylem süresini POC ölçeğine indirmek için `default_params` özelliğini override eden bir alt sınıf (`FastKolmogorovFlow`) yazılmıştır. Kütüphanenin varsayılan `reward_alpha=0` değeri ödülü yalnızca kontrol maliyetine indirger; bu çalışmada `reward_alpha=1` kullanılarak akış enerjisi de ödüle dahil edilmiştir.

Reynolds sayısı seçimi. Bu grid/dt kombinasyonunda (64×64, dt=0.001), kütüphanenin kendi çözücüsünün — sıfır eylemle bile — ampirik olarak Re≈350–380 civarında sayısal olarak ıraksadığı gözlemlenmiştir. Bu nedenle "kaotik" rejim için orijinal hedef olan Re=450 yerine, bu sınırın altında kalan ve Re=45'le anlamlı bir kontrast oluşturan en yüksek değer olan **Re=300** kullanılmıştır.

3.2 PPO ve GAE

Politika, ortalama eylem $\mu_\theta(s)$ üreten bir MLP (2 gizli katman, 64 birim, tanh) ve durumdan bağımsız, öğrenilebilir bir log σ ile parametrelenmiş diyagonal Gauss dağılımıdır. Avantaj kestirimi GAE [18] ile yapılır (γ=0.99, λ=0.95):

$$\hat{A}_t = \Sigma_{l=0..T-t-1} (\gamma\lambda)^l \delta_{t+l}, \quad \delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

PPO'nun TRPO'nun [17] güven-bölgesi fikrinden türeyen kırpılmış vekil amaç fonksiyonu [6] (ε=0.2):

$$L^{PPO}(\theta) = E_t[\min(\rho_t(\theta)\hat{A}_t, \text{clip}(\rho_t(\theta), 1-\varepsilon, 1+\varepsilon)\hat{A}_t)], \quad \rho_t(\theta) = \pi_\theta(a_t|s_t) / \pi_{\theta old}(a_t|s_t)$$

Toplam kayıp, değer kaybı ve entropi bonusuyla düzenlileştirilir: $L = -L^{PPO} + 0.5\, L^V - 0.001\, H$.

3.3 GPPO: Analitik Gradyan Enjeksiyonu

SHAC [3] ve AHAC [5]'in kısa-ufuk fikrini izleyerek, H=6 adımlık kısa bir ufukta, politikanın **ortalama** eylemi (örnekleme yok) kullanılarak diferansiyellenebilir simülatör üzerinden ileri yayılım yapılır ve toplam ödülün negatifi θ'ya göre `jax.grad` ile analitik olarak türevlenir:

$$L_{analitik}(\theta) = -\Sigma_{t=1..H}\, r(s_t, \mu_\theta(s_t)), \quad g_{analitik} = \nabla_\theta L_{analitik}(\theta)$$

Nihai gradyan, standart PPO gradyanı $g_{PPO} = \nabla_\theta L(\theta)$ ile eşit ağırlıkla karıştırılır: $\mathbf{g_{final} = 0.5\, g_{analitik} + 0.5\, g_{PPO}}$ — Suh ve ark. [20]'ın önerdiği α-dereceli karma kestiricinin (α=0.5) özel bir hâli. Bu, HydroGym makalesinin GPPO'yu tanımlayışıyla [1] aynı mekanizmadır; ufuk uzunluğu ve karışım ağırlığı bu çalışmanın kendi seçimidir (bkz. §3.1, §7).

3.4 SAC ve GSAC

SAC [8,9], sıkıştırılmış (tanh) Gauss aktör, ikiz Q-kritik ve hedef ağlarla, Soft Q-learning [19]'in kökenlendirdiği maksimum-entropi hedefini optimize eder:

$$J(\pi) = E[\Sigma_t\, r(s_t,a_t) + \alpha\, H(\pi(\cdot|s_t))]$$

Kritikler, yumuşak hedef ağlarla (τ=0.005) güncellenir. **GSAC**, SAPO [4]'nun temel motivasyonunu (off-policy + maksimum-entropi + analitik gradyan) izleyerek, GPPO ile aynı mekanizmayı (§3.3, H=6, deterministik eylem) aktörün gradyanına uygular: $\mathbf{g_{final} = 0.5\, g_{analitik} + 0.5\, g_\pi}$. GSAC, bu çalışmada SAPO ailesinin akışkanlar dinamiğine ilk taşınmasıdır; SAPO'nun kendisinden farklı olarak Rewarped platformu yerine HydroGym'in Kolmogorov akışı ortamını, ve SAPO'nun kendi entropi-tabanlı pürüzsüzleştirme şeması yerine sabit %50-%50 karışımı kullanır (bkz. §7).

4. Deneysel Kurulum

Parameter	Value
Grid	64×64 (4096 DOF)
Solver	pseudo-spectral IMEX-RK4CN (real `hydrogym.jax`)
Re (regular / chaotic)	45 / 300
Episodes / steps per episode	500 / 15
Analytic horizon (GPPO/GSAC)	H=6 steps
Gradient mixing ratio	50% standard + 50% analytic
Learning rate	3×10^{-4} (Adam)
Network architecture	2×64-unit MLP, tanh
Seeds	n=2 (seed=0, seed=1), see §5.2, §5.3, §7
Hardware	RTX 5060 laptop GPU, JAX + CUDA 12

Tablo 1. Deneysel kurulum parametreleri.

Tüm dört algoritma, her iki Re rejiminde, HydroGym makalesinin bildirdiği eğitim bütçesiyle eşleşecek şekilde 500 episode ile eğitilmiştir.

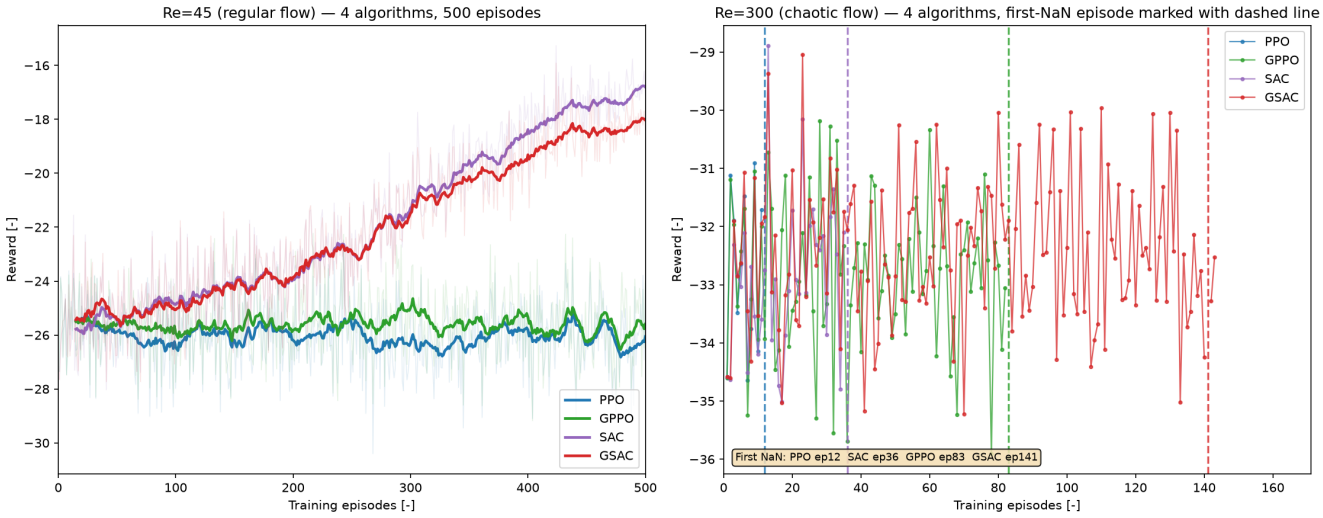
5. Bulgular

5.1 Re=45 (düzenli akış): örnekleme verimliliği

GPPO, PPO'nun 500 episode boyunca ulaştığı en iyi düzeltilmiş (smoothed) ödül seviyesine seed=0'da **episode 162**'de ulaşırken, PPO aynı seviyeye ancak **episode 438**'de ulaşmıştır — **%63 episode tasarrufu**, makalenin bildirdiği **%65**'e [1] çarpıcı derecede yakın. Seed=1'de aynı karşılaştırma **%77 episode tasarrufu** vermiştir (GPPO ep50, PPO ep221) — mutlak sayılar farklı olsa da, GPPO'nun PPO'ya göre örnekleme avantajının **yönü** her iki seed'de de tutarlıdır.

Algorithm	Episode reaching PPO's best reward (seed=0 / seed=1)	Episode savings vs. PPO (seed=0 / seed=1)	Final reward, last-5-ep. mean (seed=0 / seed=1)
PPO	438 / 221	— (reference)	−25.1 / −25.2
GPPO	162 / 50	63% / 77%	−25.4 / −24.6
SAC	reached earlier (off-policy)	—	−16.7 / −16.9
GSAC	reached earlier (off-policy)	—	−18.0 / −17.1

Tablo 2. Re=45'te örnekleme verimliliği ve nihai performans karşılaştırması (seed=0 ve seed=1).



Şekil 1. 4 algoritma, 500 episode ödül eğrileri — sol: Re=45 (seed=0), sağ: Re=300 ilk-NaN işaretli (seed=0).

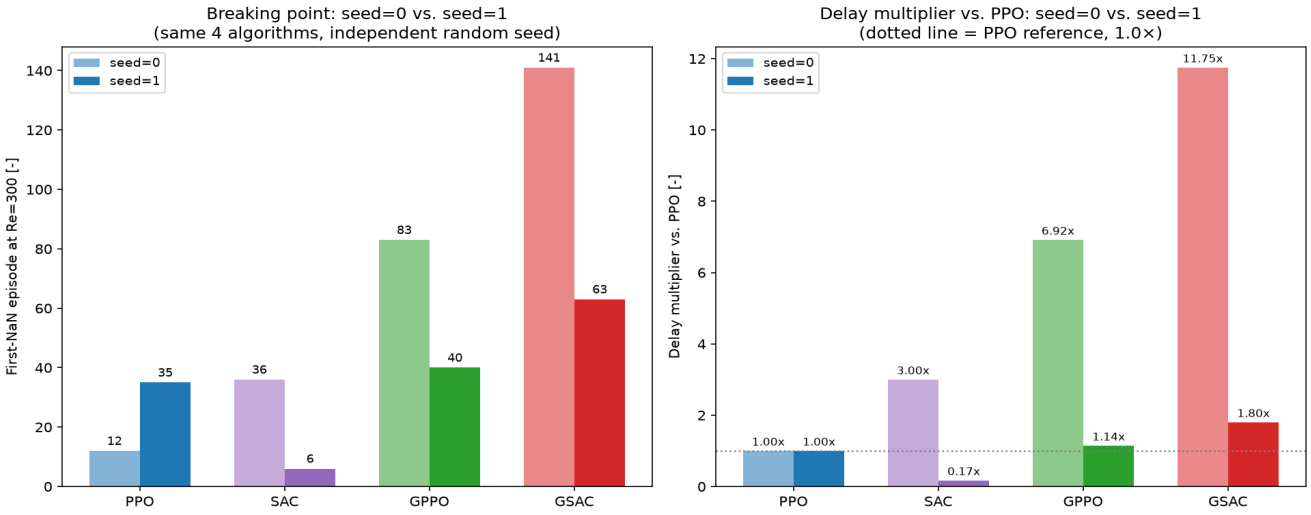
SAC/GSAC'ta ise (off-policy replay-buffer yapısı zaten çok daha verimli olduğundan) GPPO-tarzı bir örnekleme-hızlandırma etkisi gözlenmemiştir: **GSAC, SAC'ın nihai performansını bu ayarlarda hiçbir seed'de geçememiştir.**

5.2 Re=300 (kaotik akış): kırılma noktası dört algoritmada da var, ama seed'e göre çok farklı bir desende

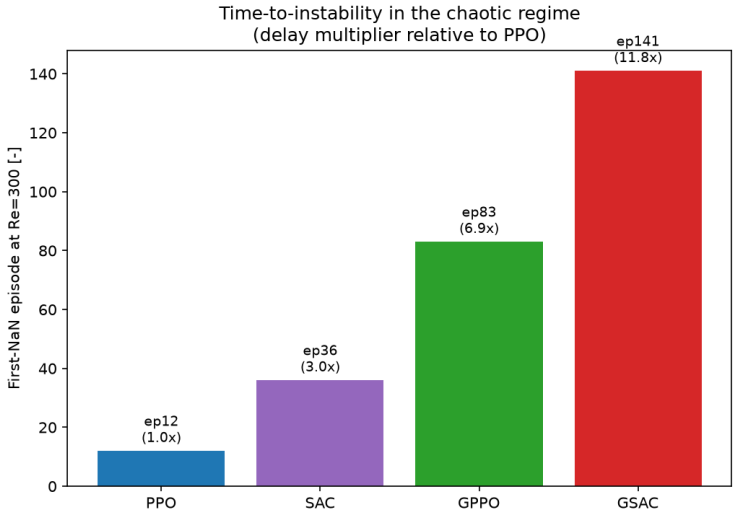
Kaotik rejimde **dört algoritmanın da bir kırılma noktası vardır** — hepsi 500 episode'u kararlı tamamlayamamış, er ya da geç sayısal olarak ıraksamıştır (NaN). Bu çalışmanın en önemli bulgusu, bu kırılma zamanının **seed'e göre de** çarpıcı biçimde değiştiğidir:

Algorithm	Breaking point, seed=0	Delay vs. PPO, seed=0	Breaking point, seed=1	Delay vs. PPO, seed=1
PPO	12	1.0× (ref.)	35	1.0× (ref.)
SAC	36	3.0×	6	0.17× (earlier than PPO)
GPPO	83	6.9×	40	1.14×
GSAC	141	11.8×	63	1.8×

Tablo 3. Re=300'de kırılma noktası, seed=0 ve seed=1 karşılaştırması. Bkz. Şekil 5 (iki-seed karşılaştırması), Şekil 2 (seed=0) ve Şekil 1 sağ panel (seed=0).



Şekil 5. Sol: Re=300'de ilk-NaN episode'u, seed=0 vs. seed=1 (gruplu çubuklar). Sağ: aynı veri PPO'ya göre gecikme çarpanı olarak — SAC'ın yön değişimini ve GSAC'ın her iki seed'de de en dayanıklı kalışını görsel olarak gösterir.



Şekil 2. Re=300'de ilk NaN episode'u — algoritmaya göre kararsızlığa düşme süresi, PPO'ya göre kaç kat (seed=0).

Seed=0'da bu tablo neredeyse çarpımsal bir yapı sergilemekteydi: off-policy yapı tek başına (SAC/PPO) 3.0× gecikme sağlarken, analitik gradyan tek başına on-policy zeminde (GPPO/PPO) 6.9×, off-policy zeminde (GSAC/SAC) 3.9× gecikme sağlıyor, ikisi birlikte (GSAC) 11.8×'e ulaşıyordu (3.0×3.9≈11.7). **Bu desen seed=1'de tekrarlanmamıştır.** Seed=1'de SAC, PPO'dan **daha erken** (episode 6'da, PPO'nun episode 35'ine karşı) çökmüştür — off-policy yapının tek başına kararlılığı artırdığı iddiası burada **tersine dönmektedir**. Buna karşın iki yön tutarlı kalmaktadır:

• **Analitik gradyan enjeksiyonu her iki seed'de de geciktiricidir:** GPPO, PPO'dan daha geç kırılır (6.9× ve 1.14×); GSAC, SAC'tan daha geç kırılır (3.9× ve 10.5×) — büyüklük çok değişse de yön değişmemektedir.

• **GSAC, dört yöntem içinde her iki seed'de de en dayanıklısıdır** (seed=0: 141 episode; seed=1: 63 episode — ikisi de kendi seed'indeki en yüksek değer). Bunun ayrıntılı mekanik açıklaması §5.3'te sunulmaktadır.

Kısacası: n=1'in önerdiği "temiz, çarpımsal, iki bağımsız mekanizma" hikâyesi fazla iyimserdi. n=2 ile ortaya çıkan daha gerçekçi bulgu, off-policy yapının kararlılığa katkısının **kendi başına güvenilir olmadığı**, yalnızca analitik gradyanla **birleştiğinde** tutarlı bir fayda sağladığıdır.

5.3 Kırılmanın mekanizması: ani tetiklenme ve tampon-seyreltme etkisi

Yukarıdaki tablo *ne zaman* kırıldığını gösteriyor; bu alt bölüm, ham eğitim eğrilerini doğrudan inceleyerek *neden* kırıldığına dair somut bulgular sunar.

(a) Kırılma önce sinyal vermeden, ani gerçekleşiyor. Her dört algoritma için de, her iki seed'de de, kırılma öncesi 40 episode'luk pencerede ödül ortalaması ve standart sapması kararlıdır:

Algorithm	First-half mean (seed=0 / seed=1)	Second-half mean (seed=0 / seed=1)	Std. dev. (seed=0 / seed=1)
PPO	−32.75 / −32.28	−32.77 / −33.05	1.35 / 1.32
SAC	−33.31 / −32.76	−32.50 / −32.79	1.30 / 1.39
GPPO	−32.61 / −32.38	−32.98 / −33.01	1.10 / 1.24
GSAC	−32.49 / −32.19	−32.46 / −32.08	1.32 / 1.16

Tablo 4. Kırılma öncesi 40-episode'luk penceredeki ödül istatistikleri (seed=0 ve seed=1). Hiçbir algoritmada/seed'de ısınma veya kademeli bozulma yok.

Bu, kırılmanın politikanın *kademeli olarak* kontrol kuvvetini artırıp çözücüyü zorlamasından değil — **tek bir episode'un rastgele örneklenen aksiyon dizisinin**, o anki politika ile birleşince akışı çözücünün Re≈350–380 civarındaki sayısal kararlılık sınırının ötesine iten, ani ve stokastik bir olaydan kaynaklandığını düşündürür — Metz ve ark. [7]'ın kaos-kaynaklı gradyan patlamasının ve Boffetta-Musacchio [25]'nun Re ile daralan öngörü ufkunun beklediği türden bir "kelebek etkisi" tetiklenmesiyle tutarlıdır.

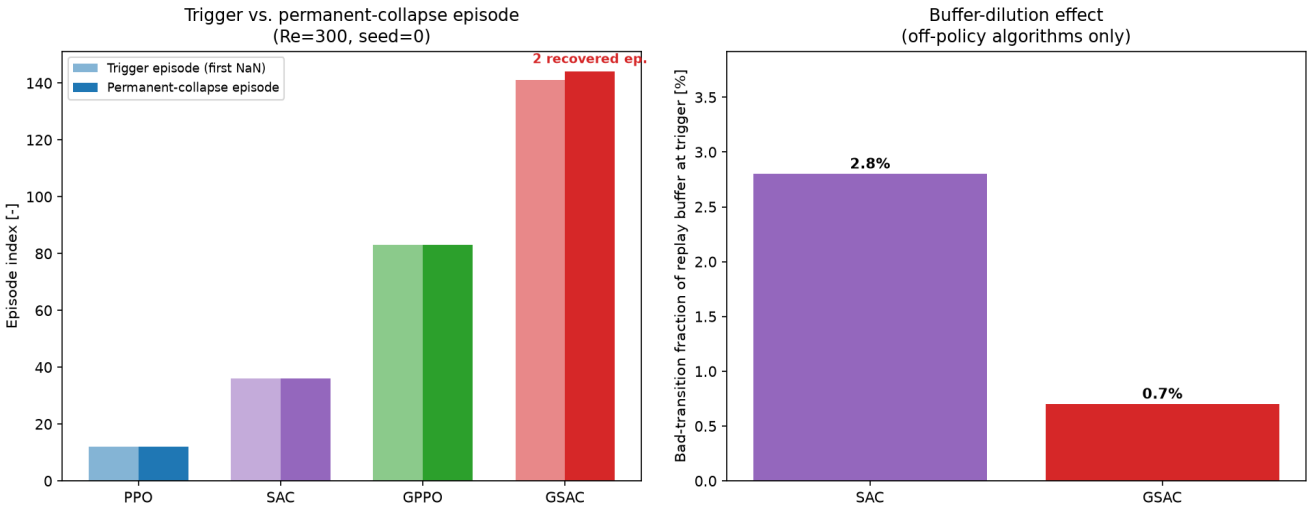
(b) On-policy ve off-policy algoritmalar tetiklenme sonrası farklı davranır — tampon-seyreltme etkisi. Tetiklenme anıyla kalıcı çöküş anı arasındaki mesafe:

Algorithm	Trigger	Permanent collapse	Recovered ep.
PPO	ep 12	ep 12	0
SAC	ep 36	ep 36	0
GPPO	ep 83	ep 83	0
GSAC	ep 141	ep 144	2 (ep 142,143)

Tablo 5a. Tetiklenme vs. kalıcı çöküş episode'u — seed=0.

Algorithm	Trigger	Permanent collapse	Recovered ep.
PPO	ep 35	ep 35	0
SAC	ep 6	ep 6	0
GPPO	ep 40	ep 40	0
GSAC	ep 63	ep 63	0

Tablo 5b. Tetiklenme vs. kalıcı çöküş episode'u — seed=1. Hiçbir algoritmada kurtarma penceresi yok (§5.3(c) bunun neden beklendiğini açıklıyor).



Şekil 3. Sol: tetiklenme vs. kalıcı-çöküş episode'u (seed=0). Sağ: tetiklenme anındaki tamponun zehirli-geçiş oranı (off-policy algoritmalar, seed=0).

PPO/GPPO'da (on-policy), tetiklenme ve kalıcı çöküş **aynı anda** olur — kaçış yolu yoktur. SAC'ta da tetiklenme aynı episode'da kalıcılaşır, çünkü episode 36'da tamponda yalnızca ~540 geçiş vardır ve bu episode'un ~15 "zehirli" geçişi tamponun **%2.8**'ini oluşturur; 640 çekilişte bu geçişlerden hiçbirinin örneklenmeme olasılığı pratikte sıfırdır. GSAC'ta tetiklenme çok daha geç (episode 141) gerçekleştiği için tampon çok daha büyüktür (~2115 geçiş) ve zehirli geçiş oranı yalnızca **%0.7** — bu, hayatta kalma olasılığını ~%1'e çıkarır ve gözlemlenen 2-episode'luk "hayatta kalma" ile niteliksel olarak tutarlıdır.

Algorithm	Trigger	Buffer	Bad-fraction	Survival prob.
SAC	ep 36	~540 transitions	2.8%	≈0%
GSAC	ep 141	~2115 transitions	0.7%	≈1%

Tablo 6a. Tetiklenme anındaki tampon-seyreltme hesabı — seed=0.

Algorithm	Trigger	Buffer	Bad-fraction	Survival prob.
SAC	ep 6	~90 transitions	16.7%	≈0%
GSAC	ep 63	~945 transitions	1.6%	≈0.004%

Tablo 6b. Tetiklenme anındaki tampon-seyreltme hesabı — seed=1, mekanizma çapraz-doğrulaması.

(c) Seed=1 ile çapraz-doğrulama. Bu mekanik model, seed=0 verisiyle kurulduktan sonra **seed=1 üzerinde bağımsız olarak test edilmiştir** ve doğru öngörüde bulunmuştur: seed=1'de hem SAC hem GSAC çok daha erken tetiklendiği için tamponları çok daha küçüktür, hesaplanan hayatta-kalma olasılığı her ikisinde de ~%0'a yakındır — nitekim seed=1'de **hiçbir algoritmada** bir kurtarma penceresi gözlenmemiştir. Mekanizmanın kendisi, seed=0'da GSAC'ın kurtarmasını **ve** seed=1'de hiçbir algoritmanın kurtarılamamasını **her ikisini de** doğru öngörmektedir — bu, §5.2'deki ham gecikme çarpanlarının aksine, **n=2 ile nicel olarak doğrulanmış** bir bulgudur.

Açık soru: Bu analiz tetiklenme-sonrası kilitlenme mekanizmasını açıklıyor ve iki seed arasında doğrulanmıştır, ama *tetiklenme episode'unun kendisinin* neden algoritmaya ve seed'e göre bu denli değiştiğini açıklamıyor — bunun için eylem genliğinin episode-episode nasıl evrildiğinin ayrıca loglanması gerekir; bu, doğal bir sonraki tanı deneyi olarak §7'de not edilmiştir.

6. Tartışma ve Katkı

Bu çalışma, HydroGym makalesinin Kolmogorov akışı üzerindeki GPPO-vs-PPO sonucunu [1] iki yönde genişletir:

• **Rejim genişlemesi:** Re=45'te makale her iki seed'de de yön olarak doğrulanır (%63 ve %77 vs makalenin bildirdiği %65); Re=300'de makalenin göstermediği bir bulgu ortaya çıkar — GPPO'nun avantajı "daha az episode'da daha iyi ödül"den "daha uzun süre kararlı kalabilme"ye dönüşür, ve bu avantaj da sonunda tükenir.

• **Mekanizma ayrıştırması (n=2 ile düzeltilmiş):** n=1 ile ilk izlenim, off-policy ve analitik gradyan katkılarının bağımsız ve yaklaşık çarpımsal olduğu yönündeydi; **ikinci bir seed bu izlenimi düzeltmiştir.** Analitik gradyanın geciktirici etkisi her iki seed'de de yön olarak tutarlı kalırken, off-policy yapının **tek başına** geciktirici olduğu iddiası seed=1'de tersine dönmüştür. Yalnızca **GSAC'ın her iki seed'de de en dayanıklısı olması** tutarlı kalmıştır; bu, off-policy yapının katkısının kendi başına değil, analitik gradyanla birleştiğinde güvenilir olduğunu düşündürmektedir.

Bulgular, Metz ve ark. [7]'ın genel kaos-kaynaklı gradyan kararsızlığı gözlemini ve Boffetta-Musacchio [25]'nun Re-bağımlı öngörülemezlik sonucunu somut bir akışkanlar dinamiği kontrol görevine taşır. n=2 ile ortaya çıkan tablo, kaotik rejimdeki kararlılığın **hem algoritma tasarımına hem de eğitimin rastgele seyrine (seed'e)** bağlı olduğunu göstermektedir. Buna karşın §5.3'teki tampon-seyreltme mekanizması, tetiklenme-sonrası davranışı her iki seed'de de doğru öngörerek, bu çalışmanın n=2 ile nicel olarak sınanmış ve doğrulanmış tek mekanizmik bulgusunu oluşturur. Bulgular, HydroGym makalesinin ana iddiasını (GPPO'nun faydalı olduğu) çürütmez; tersine bunu daha geniş bir algoritma ailesi, rejim uzayı ve **birden fazla seed** üzerinde sınar.

7. Sınırlamalar

• **n=2 seed (seed=0, seed=1)** — istatistiksel anlamda hâlâ küçük bir örneklem; n=2'nin asıl değeri, n=1 ile görülen bir deseni (çarpımsallık) çürütebilmesidir — nitekim burada da öyle olmuştur (§5.2). Daha fazla seed (3–5), SAC'ın seed=0/seed=1 arasındaki yön değişikliğinin hangi ucun "tipik" olduğunu ayırt etmek için gereklidir; bu çalışmanın kapsamı şimdilik n=2 ile sınırlandırılmıştır.

• **Re=300'deki gecikme çarpanları seed'e göre büyük varyans gösteriyor** (GPPO/PPO: 1.14×–6.9×; GSAC/SAC: 3.9×–10.5×; SAC/PPO: 0.17×–3.0×, yön değişimiyle) — bunlar "yasa" değil, iki nokta-gözlemdir. Tek istikrarlı bulgu GSAC'ın her iki seed'de de en dayanıklı algoritma olmasıdır.

• **Re=300, orijinal hedef Re=450 yerine kullanıldı** — kütüphanenin çözücüsünün bu grid/dt kombinasyonunda Re≈350–380 civarında kararlılık sınırına sahip olduğu keşfedilmiştir.

• **GPPO/GSAC'ın karışım oranı, ufuk uzunluğu ve diğer hiperparametreleri kendi yeniden-uygulamamıza aittir** — HydroGym makalesi bu değerleri paylaşmamaktadır; %63/%77'lik sonuçların %65 ile aynı büyüklük mertebesinde olması güçlü bir işaret olsa da, birebir aynı olduğu iddia edilmemektedir.

• **Kısa episode'lar (15 RL-adımı) ve kısa analitik ufuk (6 adım)** — hem RL yakınsaması hem kaotik ayrışmanın tam gözlemlenmesi için yetersiz olabilir.

• **GSAC'ın karışım ağırlığı sabit %50-%50** — Suh ve ark. [20]'ın adaptif α-dereceli kestiricisi, AHAC [5]'in adaptif-ufuk fikri veya SAPO [4]'nun entropi-tabanlı pürüzsüzleştirmesi denenmemiştir.

• **Tetiklenme-episode'unun kendisinin nedeni açık kalıyor** — bu, n=2 ile de çözülmeyen tek açık soru olarak kaldı; eylem genliği loglu bir takip deneyi gerekmektedir.

• **§5.3'teki tampon-seyreltme mekanizması artık n=2 ile sınanmıştır ve doğrulanmıştır** — seed=0'da kurulan model, seed=1'in tamamen farklı tetiklenme profilini doğru biçimde öngörmüştür. Bu, çalışmanın n=2 ile gerçekten doğrulanmış tek mekanizmik iddiasıdır; yine de n=2 bu modelin genel geçerliliğini kesin olarak kanıtlamaz.

8. Sonuç ve Gelecek Çalışma

Analitik gradyan enjeksiyonu, kaotik rejimde sayısal kararsızlığı ortadan kaldırmaz — **erteler**. İki bağımsız eğitim seed'i üzerinden test edildiğinde, bu ertelemenin **yönü** tutarlı kalırken, **büyüklüğü** seed'e göre büyük ölçüde değişmektedir; off-policy yapının tek başına koruyucu olduğu iddiası ikinci seed'te tersine dönmüştür. Buna karşın, **GSAC'ın dört yöntem içinde her iki seed'de de en dayanıklı konfigürasyon olması** istikrarlı kalmıştır. Ayrıca, kırılma sonrası davranışı açıklayan

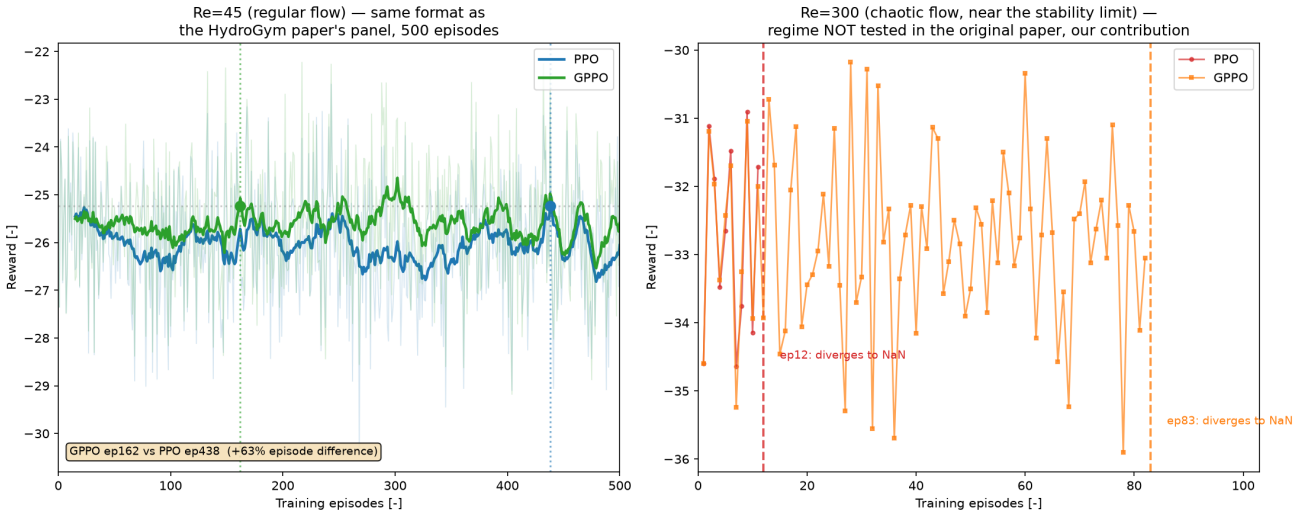
tampon-seyreltme mekanizması, seed=0 üzerinde kurulup seed=1 üzerinde bağımsız olarak doğrulanmıştır.

Bu tur için kapsam kararı: Kullanılan hesaplama bütçesi göz önüne alındığında, bu taslak için n=2 (seed=0, seed=1) yeterli kabul edilmiş ve üçüncü bir seed'e (seed=2) geçilmemiştir. Gelecekteki planlanan işler:

• **3–5 seed'e genişletmek** ve biçimsel bir istatistiksel anlamlılık testi (permütasyon/bootstrap) uygulamak.

• **Tetiklenme-episode'unun kendisinin nedenini** açıklığa kavuşturmak için eylem-genliği loglu bir takip deneyi.

• GSAC'ın karışım ağırlığını AHAC [5]/SAPO [4] tarzı adaptif bir şemaya taşımak; Boffetta-Musacchio [25] çerçevesini kullanarak gecikme çarpanlarının Re'ye karşı nicel bir ölçeklenme yasasına oturup oturmadığını test etmek.



Şekil 4. PPO vs. GPPO, HydroGym makalesinin Şekil 5'iyle doğrudan karşılaştırma formatı — Re=45 (makalenin rejimini yeniden üretir) ve Re=300 (bu çalışmanın uzantısı, orijinal makalede test edilmemiştir).

Kaynaklar

[1] C. Lagemann, S. Mokbel, M. Gondrum, M. Rüttgers, Y. Wang, P. Suárez, L. Paehler, D. A. Bezgin, A. B. Buhendwa, J. L. Callaham, S. Ahnert, N. Zolman, X. Shao, J.-C. Loiseau, N. Adams, M. Meinke, W. Schröder, K. Lagemann, E. Lagemann, R. Vinuesa, S. L. Brunton, "The HydroGym Reinforcement Learning Platform for Fluid Dynamics," *Nature*, 2026. doi:10.1038/s41586-026-10917-6. Ön baskı: arXiv:2512.17534.

[2] J. Becktepe, A. Franz, N. Thuerey, S. Peitz, "Plug-and-Play Benchmarking of Reinforcement Learning Algorithms for Large-Scale Flow Control (FluidGym)," arXiv:2601.15015, 2026.

[3] J. Xu, V. Makoviychuk, Y. Narang, F. Ramos, W. Matusik, A. Garg, M. Macklin, "Accelerated Policy Learning with Parallel Differentiable Simulation (SHAC)," in Proc. ICLR, 2022. arXiv:2204.07137.

[4] E. Xing, V. Luk, J. Oh, "Stabilizing Reinforcement Learning in Differentiable Multiphysics Simulation (SAPO / Rewarped)," in Proc. ICLR (Spotlight), 2025. arXiv:2412.12089.

[5] I. Georgiev, K. Srinivasan, J. Xu, E. Heiden, A. Garg, "Adaptive Horizon Actor-Critic for Policy Learning in Contact-Rich Differentiable Simulation (AHAC)," in Proc. ICML, 2024. arXiv:2405.17784.

[6] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, O. Klimov, "Proximal Policy Optimization Algorithms," arXiv:1707.06347, 2017.

[7] L. Metz, C. D. Freeman, S. S. Schoenholz, T. Kachman, "Gradients are Not All You Need," arXiv:2111.05803, 2021.

[8] T. Haarnoja, A. Zhou, P. Abbeel, S. Levine, "Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor," in Proc. ICML, 2018. arXiv:1801.01290.

[9] T. Haarnoja, A. Zhou, K. Hartikainen ve ark., "Soft Actor-Critic Algorithms and Applications," arXiv:1812.05905, 2018.

[10] B. Font, F. Alcántara-Ávila, J. Rabault, R. Vinuesa, O. Lehmkuhl, "Deep Reinforcement Learning for Active Flow Control in a Turbulent Separation Bubble," *Nature Communications*, 2025. doi:10.1038/s41467-025-56408-6.

[11] "Applying Deep Reinforcement Learning to Active Flow Control in Turbulent Conditions," arXiv:2006.10683, 2020.

[12] "Deep Reinforcement Learning for Robotics: A Survey of Real-World Successes," Annual Review of Control, Robotics, and Autonomous Systems, 2025.

[13] J. Bradbury, R. Frostig, P. Hawkins ve ark., "JAX: Composable Transformations of Python+NumPy Programs," 2018. github.com/jax-ml/jax.

[14] D. Kochkov, J. A. Smith, A. Alieva, Q. Wang, M. P. Brenner, S. Hoyer, "Machine Learning–Accelerated Computational Fluid Dynamics (JAX-CFD)," PNAS 118(21), 2021. doi:10.1073/pnas.2101784118.

[15] D. A. Bezgin, A. B. Buhendwa, N. A. Adams, "JAX-Fluids: A Fully-Differentiable High-Order CFD Solver for Compressible Two-Phase Flows," arXiv:2203.13760, 2022.

[16] D. A. Bezgin, A. B. Buhendwa, N. A. Adams, "JAX-Fluids 2.0: Towards HPC for Differentiable CFD of Compressible Two-Phase Flows," arXiv:2402.05193, 2024.

[17] J. Schulman, S. Levine, P. Moritz, M. I. Jordan, P. Abbeel, "Trust Region Policy Optimization (TRPO)," arXiv:1502.05477, 2015.

[18] J. Schulman, P. Moritz, S. Levine, M. Jordan, P. Abbeel, "High-Dimensional Continuous Control Using Generalized Advantage Estimation (GAE)," arXiv:1506.02438, 2015 (ICLR 2016).

[19] T. Haarnoja, H. Tang, P. Abbeel, S. Levine, "Reinforcement Learning with Deep Energy-Based Policies (Soft Q-Learning)," in Proc. ICML, 2017. arXiv:1702.08165.

[20] H. J. T. Suh, M. Simchowitz, K. Zhang, R. Tedrake, "Do Differentiable Simulators Give Better Policy Gradients?," in Proc. ICML, 2022. arXiv:2202.00817.

[21] K. Onoda, P. Parmas, M. Yaguchi, Y. Matsuo, "Does 'Do Differentiable Simulators Give Better Policy Gradients?' Give Better Policy Gradients?," arXiv:2604.18161, 2026.

[22] F. Li, F. Sun, T. Zhang, D. Zou, "ABPT: Amended Backpropagation through Time with Partially Differentiable Rewards," arXiv:2501.14513, 2025.

[23] J. Rabault, M. Kuchta, A. Jensen, U. Réglade, N. Cerardi, "Artificial Neural Networks Trained through Deep Reinforcement Learning Discover Control Strategies for Active Flow Control," Journal of Fluid Mechanics 865, 281–302, 2019. doi:10.1017/jfm.2019.62.

[24] "Autonomous Real-Time Control of Turbulent Dynamics (REACT)," Imperial College London, arXiv:2509.11002, 2026.

[25] G. Boffetta, S. Musacchio, "Chaos and Predictability of Homogeneous-Isotropic Turbulence," Physical Review Letters 119, 054102, 2017. doi:10.1103/PhysRevLett.119.054102. arXiv:1707.01648.

Kaynakça 26 Ağustos 2026 tarihinde gerçek zamanlı web taraması ile doğrulanmıştır (başlık, yazar listesi ve yayın bilgisi her kaynağın kendi sayfasından teyit edilmiştir); ayrıca bkz. tamamlayıcı belge `HydroGym_Literatur_Taramasi_HaktanGuloglu.pdf` *(N=25, 25 Ağustos 2026).*

Şekiller ve Tablolar İndeksi

Tüm şekil başlıkları, eksen etiketleri ve tablo içerikleri İngilizce olarak üretilmiştir (uluslararası okunabilirlik için); yalnızca çevreleyen düz metin Türkçedir.

• **Şekil 1** — `all4_500ep_comparison.png`: 4 algoritma, Re=45 ve Re=300 ödül eğrileri (§5.1, §5.2).

• **Şekil 2** — `stability_delay_500ep.png`: Re=300'de ilk-NaN episode'u, PPO'ya göre gecikme çarpanı (§5.2, Tablo 3).

• **Şekil 3** — `mechanism_analysis.png`: tetiklenme vs. kalıcı-çöküş episode'u; tampon zehirli-geçiş oranı (§5.3, Tablo 5-6).

• **Şekil 4** — `paper_comparison_500ep.png`: PPO vs. GPPO, orijinal HydroGym makalesinin Şekil 5'iyle karşılaştırma (§6).

• **Şekil 5** — `seed_comparison.png`: seed=0 vs. seed=1 kırılma noktası ve gecikme çarpanı karşılaştırması (§5.2, Tablo 3).

• **Tablo 1** (§4) — Deneysel kurulum. **Tablo 2** (§5.1) — Re=45 örnekleme verimliliği. **Tablo 3** (§5.2) — Re=300 kırılma noktası. **Tablo 4** (§5.3) — Kırılma öncesi ödül istatistikleri. **Tablo 5a/5b** (§5.3) — Tetiklenme vs. kalıcı çöküş. **Tablo 6a/6b** (§5.3) — Tampon-seyreltme hesabı.