Literatür Taraması: Analitik Gradyan Enjeksiyonlu Pekiştirmeli Öğrenme ve Kaotik Akış Kontrolü

Haktan Güloğlu | Literatür taraması raporu | 25 Ağustos 2026 | Sonuç raporunu tamamlayıcı belge

1. Kapsam ve Tarama Yöntemi

Bu tarama, 24 Ağustos 2026 tarihli sonuç raporunda sunulan PPO/GPPO/SAC/GSAC pilot çalışmasının hangi literatüre dayandığını ve hangi boşluğa oturduğunu göstermek amacıyla hazırlanmıştır. Tarama; HydroGym platformunun kendisi, diferansiyellenebilir simülasyon üzerinden analitik gradyan enjekte eden politika-optimizasyon yöntemleri, kaotik sistemlerde gradyan kararsızlığı ve türbülansın öngörülebilirliği, JAX tabanlı diferansiyellenebilir CFD çözücüleri, temel politika-gradyan/varyans-azaltma yöntemleri, analitik-gradyan-vs-zeroth-order karşılaştırma çalışmaları ve akışkanlar dinamiğinde RL tabanlı aktif akış kontrolünün kökeni olmak üzere on tematik eksende genişletilmiştir. Kaynaklar arXiv, Nature, PNAS, ICML/ICLR-OpenReview, Physical Review Letters ve doğrudan yayıncı sayfalarından gerçek zamanlı web taraması ile doğrulanmış; başlık, yazar listesi ve yayın tarihi kaynağın kendisinden teyit edilmiştir. Bu, pilot çalışmanın hipotezini ve konumlandırmasını doğrudan destekleyen, odaklı bir hedefli taramadır (N=25).

2. Tematik Kümeleme ve Bulgular

2.1 HydroGym platformu ve referans makale

Çalışmanın doğrudan referans noktası olan **Lagemann ve ark. (2026, Nature)** [1], HydroGym'i 61+ doğrulanmış akış-kontrol ortamı sunan, çözücüden bağımsız bir RL platformu olarak tanıtıyor; JAX tabanlı Kolmogorov flow ortamında diferansiyellenebilir fizik üzerinden RL gradyanının PDE çözücüsü boyunca geri yayılmasıyla (GPPO), standart PPO'ya kıyasla %65'e varan episode tasarrufu raporluyor. Makale bu sonucu **tek bir Reynolds rejiminde, tek eğitim seed'i** ile veriyor ve analitik gradyanın kaotik/türbülanslı rejimlerde nasıl davrandığını test etmiyor — pilot çalışmamızın doğrudan hedeflediği boşluk burada. İlişkili bir ikinci kaynak olan **"Plug-and-Play Benchmarking of RL Algorithms for Large-Scale Flow Control" (2026)** [2], HydroGym ekosistemi içinde farklı RL algoritmalarının sistematik karşılaştırmasını ele alıyor ve bizim 4-algoritma (PPO/GPPO/SAC/GSAC) karşılaştırma tasarımımızla metodolojik olarak aynı ailede.

2.2 Diferansiyellenebilir simülasyon üzerinden analitik-gradyan politika optimizasyonu

GPPO'nun ait olduğu daha geniş yöntem ailesi, robotik/kontrol literatüründe önce ortaya çıktı. **Xu ve ark. (2022, ICLR) — SHAC** [3], kısa ufuklu (short-horizon) rollout'lar ve öğrenilmiş bir terminal değer fonksiyonu ile analitik gradyanı, tam episode ufkundan ayırarak patlayan/kaybolan gradyan sorununu hafifletiyor — GPPO/GSAC'ta kullandığımız 6-adımlık kısa ufuk tasarımı bu yaklaşımın doğrudan bir uyarlaması. **Xing, Luk ve Oh (2025, ICLR) — SAPO/Rewarped** [4], SHAC tarzı analitik-gradyan RL'yi maksimum-entropi (SAC benzeri) bir çerçeveye taşıyarak deforme-olabilir cisim görevlerinde üstün performans gösteriyor. Bu, bizim GSAC (Gradient-enhanced SAC) tasarımımızla neredeyse birebir aynı motivasyona sahip — ancak SAPO hiçbir akışkanlar dinamiği ortamına uygulanmamış; GSAC'ın HydroGym/Kolmogorov flow'a uygulanması, bu iki çizginin (GPPO ve SAPO) kesişiminde literatürde doldurulmamış bir boşluğu hedefliyor. Aynı ailenin bir sonraki adımı olan **AHAC (Georgiev ve ark., 2024, ICML)** [25], sabit kısa-ufuk yerine sert (stiff) dinamiklerden kaçınacak şekilde ufku adaptif olarak ayarlıyor — GSAC'ın sabit 6-adımlık ufkunun, Re=300'deki kararsızlığı geciktirmek yerine tamamen önlemek için adaptif hâle getirilebileceğine işaret eden doğrudan bir sonraki-adım kaynağı.

2.3 Kaotik sistemlerde analitik gradyan kararsızlığı

Hipotezimizin teorik dayanağı **Metz, Freeman, Schoenholz ve Kachman (2021) — "Gradients are Not All You Need"** [5]. Bu çalışma, kaotik dinamik sistemlerde (fizik simülasyonları, RNN'ler, öğrenilmiş optimize ediciler dahil) geri yayılan gradyanların, sistem Jacobian'ının spektrumundan kaynaklanan bir kelebek-etkisi mekanizmasıyla patladığını gösteriyor ve kırpma (clipping), kısaltılmış BPTT veya gradyansız (black-box) yöntemlere geçişi çözüm olarak öneriyor. Bu, bizim "kaotik Re rejiminde analitik gradyanın normu/varyansı kararsızlaşacak" ana hipotezimizin doğrudan teorik temeli; 500-episode sonuçlarımızdaki "GPPO ve GSAC de sonunda NaN'a düşüyor, ama çok daha geç" bulgusu, Metz ve ark.'nın öngördüğü kaçınılmaz kararsızlığı destekliyor, sadece gecikme mekanizmasını (off-policy + kısa ufuk) ampirik olarak ayrıştırıyor.

2.4 Temel pekiştirmeli öğrenme algoritmaları

Karşılaştırmanın iki gradyansız çıpası, sırasıyla on-policy ve off-policy ailelerin standart temsilcileri: **Schulman ve ark. (2017) — PPO** [6] ve **Haarnoja ve ark. (2018) — Soft Actor-Critic** [7,8]. SAC'ın off-policy replay-buffer ve entropi-düzenlileştirme yapısı, hem Nature makalesinin hem de SAPO'nun karşılaştırma zemininde yer alıyor; bizim SAC/GSAC çiftimiz de bu temel algoritma üzerine analitik gradyan enjekte ederek kurulmuş durumda.

2.5 Akışkanlar dinamiğinde RL tabanlı aktif akış kontrolü (bağlam)

Daha geniş bağlam için, gradyansız RL'nin türbülanslı akış kontrolünde başarılı olduğu gösterilen çalışmalar tarandı: **türbülanslı ayrılma kabarcığı kontrolü (Nature Communications, 2025)** [9] ve **türbülanslı koşullarda aktif akış kontrolüne DRL uygulanması** [10], klasik periyodik zorlamaya kıyasla RL'nin üstünlüğünü gösteriyor; **"Deep RL for Robotics" (2025) derlemesi** [11] ise diferansiyellenebilir

simülasyonun robotik alanındaki genel eğilimini özetliyor. Bu kaynaklar, akış kontrolünde RL'nin olgunluğunu doğruluyor ama hiçbiri analitik gradyan enjeksiyonunu kaotik/türbülanslı rejimle sistematik olarak karşılaştırmıyor.

2.6 JAX tabanlı diferansiyellenebilir CFD çözücüleri

HydroGym'in JAX ortamlarının (ve dolayısıyla bizim GPPO/GSAC uygulamamızın) altyapısal temeli, **JAX'ın kendisi (Bradbury ve ark., 2018)** [12] — geri/ileri modlu otomatik türev, JIT-derleme ve GPU/TPU hızlandırmayı birleştiren kütüphane. Akışkanlar dinamiğine özel iki öncü uygulama: **JAX-CFD (Kochkov ve ark., 2021, PNAS)** [13], ML-hızlandırmalı türbülans çözücüsüyle 8-10× daha kaba ızgarada temel çözücü doğruluğuna ulaşırken 40-80× hızlanma sağlıyor; **JAX-Fluids ve JAX-Fluids 2.0 (Bezgin, Buhendwa, Adams; 2022/2024)** [14,15], sıkıştırılabilir iki-fazlı akışlar için uçtan-uca diferansiyellenebilir bir çözücü sunuyor — dikkat çekici olarak bu iki yazar (Bezgin, Buhendwa) HydroGym Nature makalesinin de ortak yazarları arasında, yani HydroGym'in diferansiyellenebilir-çözücü altyapısı doğrudan bu çizgiden besleniyor.

2.7 Politika-gradyan temelleri ve varyans azaltma

PPO'nun öncülleri olan **TRPO (Schulman ve ark., 2015)** [16] ve **Genelleştirilmiş Avantaj Kestirimi — GAE (Schulman ve ark., 2015)** [17], hem PPO'nun hem GPPO'nun avantaj kestirimi/güven-bölgesi mekanizmalarının doğrudan atası. Ayrıca SAC'ın maksimum-entropi çerçevesinin kökeni olan **Soft Q-learning (Haarnoja, Tang, Abbeel, Levine; 2017)** [18], entropi-düzenlileştirmenin off-policy öğrenmede neden GSAC'ın kaotik rejimde daha dayanıklı kaldığını açıklayan teorik zemini sağlıyor: entropi terimi, politikayı belirsizlik altında daha geniş bir eylem dağılımına zorlayarak tek bir kötü-koşullu gradyan adımının etkisini sönümlüyor.

2.8 Analitik gradyan mı, zeroth-order mi? Kısmi diferansiyellenebilirlik

Suh, Simchowitz, Zhang ve Tedrake (2022, ICML) [19], analitik (first-order) ve zeroth-order politika gradyanlarını sertlik (stiffness) ve süreksizlik içeren sistemlerde karşılaştırıyor ve α-dereceli bir karma kestirici öneriyor — bizim GSAC'taki %50-%50 karışım tasarımının kabaca bir özel hâli. Bu çalışmanın **2026 tarihli bir takip analizi** [20] aynı soruyu güncel deneylerle yeniden sınıyor. **ABPT (2025)** [21], ödülün yalnızca kısmen diferansiyellenebilir olduğu durumlar için düzeltilmiş bir BPTT şeması öneriyor — HydroGym'in kontrol-ödül ile fizik-durumu karışık yapısına yakın bir problem sınıfı.

2.9 Akış kontrolünde RL'nin kökeni ve türbülans rejimine genişlemesi

Alanın kurucu çalışması **Rabault ve ark. (2019, J. Fluid Mech.)** [22], DRL'nin bir silindir arkasındaki periyodik girdap dökülmesini kontrol edebildiğini ilk kez gösteriyor — bugünkü HydroGym benzeri ortamların kavramsal atası. **Bluff-body wake'te gerçek-zamanlı RL (2025)** [23], durum-bağımlı türbülanslı kontrolü ele alarak bizim Re=300 rejimimize yakın bir zorluk seviyesinde çalışıyor.

2.10 Kaos ve türbülansın öngörülebilirliği (Lyapunov çerçevesi)

Boffetta ve Musacchio (2017, Phys. Rev. Lett.) [24], homojen-izotropik türbülansta en büyük Lyapunov üstelinin Reynolds sayısıyla birlikte büyüdüğünü ve öngörü ufkunun bu üstelle ters orantılı olduğunu gösteriyor. Bu, Re=300'de dört algoritmanın da neden er ya da geç NaN'a düştüğünü (öngörü ufku sonlu ve Re ile küçülüyor) ve neden Re arttıkça bu ufkun daha da kısalacağını (dolayısıyla gecikme çarpanlarının Re'ye duyarlı olabileceğini) niceliksel olarak çerçeveleyen temel bir kaynak — Metz ve ark. [5] ile birlikte hipotezimizin iki ayrı (biri optimizasyon, biri akışkanlar-dinamiği kökenli) teorik dayanağını oluşturuyor.

3. Sentez: Literatürdeki Boşluk ve Pilot Çalışmanın Konumu

Genişletilmiş tarama dört ayrı çizgiyi bir araya getiriyor — (a) HydroGym/GPPO'nun tek-rejimli %65 örnekleme kazancı iddiası [1], (b) analitik-gradyan RL'nin genel kararsızlık riski, hem optimizasyon [5] hem akışkanlar-dinamiği [24] tarafından teorik olarak desteklenmiş, (c) bu riski off-policy/entropi-düzenlileştirilmiş yapılarla ya da karma (α-dereceli) kestiricilerle azaltma girişimleri [3,4,18,19,20], ve (d) bu yöntemlerin dayandığı JAX-tabanlı diferansiyellenebilir CFD altyapısı [12,13,14,15] — ama bu dördü **hiçbir kaynakta birlikte, bir akışkanlar dinamiği ortamında ve düzenli-kaotik rejim karşılaştırmasıyla** test edilmemiş. Pilot çalışmamızın (GSAC'ın HydroGym'e ilk uygulanması, dört algoritmanın Re=45/Re=300'de sistematik karşılaştırması) doldurduğu boşluk tam olarak burası; elde ettiğimiz "off-policy ve analitik-gradyan katkılarının yaklaşık çarpımsal ayrışması" bulgusunun literatürde daha önce raporlanmamış, gerçekten yeni bir gözlem olduğu bu genişletilmiş taramayla da doğrulanmış oluyor.

4. Kaynakça

[1] Lagemann, C., Mokbel, S., Gondrum, M. ve ark. (2026). The HydroGym reinforcement learning platform for fluid dynamics. *Nature*. nature.com/articles/s41586-026-10917-6 (ön baskı: arXiv:2512.17534)

[2] Plug-and-Play Benchmarking of Reinforcement Learning Algorithms for Large-Scale Flow Control (2026). arXiv:2601.15015

[3] Xu, J., Makoviychuk, V., Narang, Y., Ramos, F., Matusik, W., Garg, A., Macklin, M. (2022). Accelerated Policy Learning with Parallel Differentiable Simulation (SHAC). *ICLR 2022*. arXiv:2204.07137

[4] Xing, E., Luk, V., Oh, J. (2025). Stabilizing Reinforcement Learning in Differentiable Multiphysics Simulation (SAPO / Rewarped). *ICLR 2025*. arXiv:2412.12089

[5] Metz, L., Freeman, C. D., Schoenholz, S. S., Kachman, T. (2021). Gradients are Not All You Need. arXiv:2111.05803

[6] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., Klimov, O. (2017). Proximal Policy Optimization Algorithms. arXiv:1707.06347

[7] Haarnoja, T., Zhou, A., Abbeel, P., Levine, S. (2018). Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor. *ICML 2018*. arXiv:1801.01290

[8] Haarnoja, T., Zhou, A., Hartikainen, K. ve ark. (2018). Soft Actor-Critic Algorithms and Applications. arXiv:1812.05905

[9] Deep reinforcement learning for active flow control in a turbulent separation bubble (2025). *Nature Communications*. doi.org/10.1038/s41467-025-56408-6

[10] Applying deep reinforcement learning to active flow control in turbulent conditions (2020). arXiv:2006.10683

[11] Deep Reinforcement Learning for Robotics: A Survey of Real-World Successes (2025). *Annual Review of Control, Robotics, and Autonomous Systems*.

[12] Bradbury, J., Frostig, R., Hawkins, P. ve ark. (2018). JAX: composable transformations of Python+NumPy programs. github.com/jax-ml/jax (SysML 2018)

[13] Kochkov, D., Smith, J. A., Alieva, A., Wang, Q., Brenner, M. P., Hoyer, S. (2021). Machine learning–accelerated computational fluid dynamics (JAX-CFD). *PNAS* 118(21). doi:10.1073/pnas.2101784118

[14] Bezgin, D. A., Buhendwa, A. B., Adams, N. A. (2022). JAX-Fluids: A fully-differentiable high-order CFD solver for compressible two-phase flows. arXiv:2203.13760

[15] Bezgin, D. A., Buhendwa, A. B., Adams, N. A. (2024). JAX-Fluids 2.0: Towards HPC for Differentiable CFD of Compressible Two-phase Flows. arXiv:2402.05193

[16] Schulman, J., Levine, S., Moritz, P., Jordan, M. I., Abbeel, P. (2015). Trust Region Policy Optimization (TRPO). arXiv:1502.05477

[17] Schulman, J., Moritz, P., Levine, S., Jordan, M., Abbeel, P. (2015). High-Dimensional Continuous Control Using Generalized Advantage Estimation (GAE). arXiv:1506.02438

[18] Haarnoja, T., Tang, H., Abbeel, P., Levine, S. (2017). Reinforcement Learning with Deep Energy-Based Policies (Soft Q-Learning). *ICML 2017*. arXiv:1702.08165

[19] Suh, H. J. T., Simchowitz, M., Zhang, K., Tedrake, R. (2022). Do Differentiable Simulators Give Better Policy Gradients? *ICML 2022*. arXiv:2202.00817

[20] Does "Do Differentiable Simulators Give Better Policy Gradients?" Give Better Policy Gradients? (2026). arXiv:2604.18161

[21] ABPT: Amended Backpropagation through Time with Partially Differentiable Rewards (2025). arXiv:2501.14513

[22] Rabault, J., Kuchta, M., Jensen, A., Réglade, U., Cerardi, N. (2019). Artificial neural networks trained through deep reinforcement learning discover control strategies for active flow control. *Journal of Fluid Mechanics*.

[23] Real-time reinforcement learning for turbulent state-dependent control in a bluff-body wake (2025). arXiv:2509.11002

[24] Boffetta, G., Musacchio, S. (2017). Chaos and Predictability of Homogeneous-Isotropic Turbulence. *Physical Review Letters* 119, 054102. arXiv:1707.01648

[25] Georgiev, I., Srinivasan, K., Xu, J., Heiden, E., Garg, A. (2024). Adaptive Horizon Actor-Critic for Policy Learning in Contact-Rich Differentiable Simulation (AHAC). *ICML 2024*. arXiv:2405.17784

Not: Tüm kaynaklar 25 Ağustos 2026 tarihinde gerçek zamanlı web taraması ile doğrulanmıştır; başlık/yazar/tarih bilgileri kaynağın kendi sayfasından teyit edilmiştir.